

E-COMMERCE SALES ANALYTICS

Аналитический отчёт по продажам интернет-магазина

Источник данных: ecommerce_sales_analytics_5000.xlsx

Объём выборки: 5 000 заказов (2022-2035)

Подготовлено: Data Analyst Portfolio Project

Инструменты: Python (pandas, matplotlib), очистка и валидация данных

1. Данные и предобработка

Исходный файл содержал 5 000 заказов и 12 столбцов: идентификаторы заказа и клиента, дату заказа, категорию товара, регион, количество, цену за единицу, скидку, способ оплаты, срок доставки, оценку клиента и выручку. Перед анализом данные были проверены на целостность — обнаружено три типа проблем, которые исправлены до построения графиков.

Обнаруженные проблемы качества данных

Столбец	Проблема	% строк	Решение
customer_rating	Значения заменены случайными датами (баг формата ячейки Excel)	89.7%	Признано невозможным — столбец исключён из анализа выручки, отмечен как ограничение
order_date	У части дат год записан как «19xx» вместо «20xx» (опечатка на 100 лет)	16.5%	Год скорректирован на +100 лет по совпадающему шаблону в соседних строках
unit_price	Значения заменены датами (тот же баг формата)	0.7%	Восстановлено из формулы $revenue = quantity \times unit_price \times (1 - discount)$
revenue	Значения заменены датами (тот же баг формата)	0.1%	Восстановлено из той же формулы; 1 строка с двойной порчей — удалена



Итог очистки: из 5 000 строк удалена 1 (невозможная), итоговая выборка для анализа выручки — 4 999 заказов. Столбец customer_rating сохранён в очищенном файле, но помечен как ненадёжный (валидны только 515 значений из 4 999, 10.3%) и не используется в ключевых выводах.

2. Обзорный дашборд

E-COMMERCE SALES — ОБЗОРНЫЙ ДАШБОРД

Период: Jan 2022 - Dec 2035 | Заказов: 4 999

\$5.11M

Общая выручка

4 999

Всего заказов


\$1 022

Средний чек (AOV)


18.0%

Средняя скидка

Динамика выручки по месяцам



Выручка по категориям товаров



Выручка по регионам



Ключевые наблюдения


- Общая выручка за период — \$5.11M по 4 999 заказам, средний чек — \$1 022.
- Electronics — самая прибыльная категория (35.8% выручки, \$1.83M), почти в 2.4 раза больше, чем Beauty (наименьшая категория).
- Выручка распределена по регионам довольно равномерно (West — \$1.35M, East — \$1.24M), разброс между регионами не превышает 9%.
- Средняя скидка по заказам — 18% при разбросе от 0% до 35%.

3. Детальный анализ


E-COMMERCE SALES — ДЕТАЛЬНЫЙ АНАЛИЗ

Способы оплаты · Скидки · Доставка · Категории по регионам


Доля выручки по способу оплаты




Распределение сроков доставки (дни)



Скидка (%) vs Выручка за заказ



Категория × Регион (выручка, \$K)



Ключевые наблюдения

- Card — основной способ оплаты (46% выручки), далее COD (35%) и Wallet (19%).
- Срок доставки распределён практически равномерно от 1 до 11 дней — выраженной концентрации нет, что может говорить о нестабильности логистики.
- Слабая отрицательная связь между скидкой и выручкой за заказ (коэффициент корреляции ≈ -0.14): большие скидки не приводят к заметному росту суммы чека.
- В разрезе категория × регион заметных региональных перекосов нет — Electronics лидирует во всех регионах примерно одинаково.

4. Выводы и рекомендации

Бизнес-выводы

- Ставку стоит делать на Electronics и Clothing — вместе они дают 65.8% выручки; для Beauty и Home имеет смысл проверить причины низкого спроса (ассортимент, цены, продвижение).
- Регионы сбалансированы — точечных проблемных зон нет, единой региональной стратегии может быть недостаточно, лучше смотреть на уровне категорий внутри региона.
- Скидки в текущем виде не работают как драйвер выручки — отрицательная корреляция говорит о том, что глубокие скидки скорее применяются к изначально более дешёвым позициям, а не стимулируют более крупные покупки.
- Равномерное распределение сроков доставки (1-11 дней) стоит обсудить с логистикой — большой разброс может снижать удовлетворённость клиентов.

Ограничения анализа

- Столбец `customer_rating` повреждён на 89.7% и исключён — оценка удовлетворённости клиентов в этом отчёте не рассматривается.
- Данные охватывают заказы с 2022 по 2035 год; для дат с исправленным годом (19xx→20xx) сделано допущение на основе шаблона в соседних строках, а не подтверждено первоисточником.

Что можно добавить дальше

- Повторный экспорт данных с корректным полем `customer_rating` для анализа связи оценки с категорией, регионом и сроком доставки.
- RFM-сегментация клиентов (Recency, Frequency, Monetary) по `customer_id`.
- Когортный анализ удержания клиентов во времени.